

ΕΠΕΞΕΡΓΑΣΙΑ ΔΕΔΟΜΕΝΩΝ ΚΑΙ ΑΛΓΟΡΙΘΜΟΙ ΜΑΘΗΣΗΣ

Ακαδημαϊκό Έτος 2020-2021



ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

3^ο Σετ Ασκήσεων

Φώτιος-Παναγιώτης	Μπασαμάκης	1046975
-------------------	------------	---------

ΠΡΟΒΛΗΜΑ 1:

Έχω μια μεταβλητή ομοιόμορφα κατανομημένη στο διάστημα $[0, 1]$ καθώς και 1000 υλοποιήσεις της συγκεκριμένης μεταβλητής. Για αυτό το λόγο γνωρίζω θεωρητικά ότι η συνάρτηση πυκνότητας πιθανότητας της θα είναι η εξής:

$$f(x) = \begin{cases} 1, & 0 \leq x \leq 1 \\ 0, & 0 < x \text{ ή } x > 1 \end{cases}$$

Σκοπός μου είναι να προσεγγίσω αυτή τη συνάρτηση πυκνότητας πιθανότητας με πυρήνες kernel.

Αρχικά γνωρίζουμε ότι η συνάρτηση dirac $\delta(x)$ έχει τις παρακάτω ιδιότητες:

- $\int \Phi(x)\delta(x)dx = \Phi(0)$
- $\int \delta(x)dx=1$
- $f(x) = \begin{cases} \infty, & x = 0 \\ 0, & x \neq 0 \end{cases}$

Αναζητώ μια συνάρτηση η οποία προσεγγίζει την $\delta(x)$ και έτσι ορίζω τον πυρήνα Kernel

$K(x, h) = g\left(\frac{x}{h}\right)\left(\frac{1}{h}\right)$ όπου προσεγγίζει την $\delta(x)$ όταν το h τείνει στο 0

Λαμβάνοντας υπόψη τις παρακάτω ιδιότητες:

$$\int \Phi(x)\delta(x - x_0)dx = \Phi(x_0)$$

$$\frac{G(x_1, y) + G(x_2, y) + \dots + G(x_N, y)}{N} = E_X[G(X, y)]$$

(Όπου $E_X[G(X, y)]$ ο μέσος όρος που προσεγγίζεται από την παραπάνω σχέση λόγω νόμου των μεγάλων αριθμών)

Η συνάρτηση πυκνότητας πιθανότητας προσεγγίζεται μέσω των πυρήνων ως εξής:

$$f'(y) = \int f'(x)\delta(x - y)dx = \int f'(x)K(x - y, h)dx = E_X[K(x - y, h)]$$

Όπου τελικά

$$f'(x) = \frac{K(x - x_1, h) + K(x - x_2, h) + \dots + G(x - x_N, h)}{N}$$


Βάση λοιπόν της παραπάνω λογικής αναπτύχθηκε κώδικας στο matlab για προσέγγιση της συνάρτησης πυκνότητας πιθανότητας χρησιμοποιώντας τον παρακάτω πυρήνα kernel

$$K(x, h) = \frac{1}{\sqrt{2\pi h}} e^{-\frac{1}{2h}x^2}.$$

Τα αποτελέσματα για διάφορες τιμές του h είναι τα εξής:


$h = 0.001$

gaussian




$h = 0.01$

gaussian



$h = 0.1$

gaussian



Παρατηρώ ότι όσο μικραίνει το h τόσο πιο γρήγορα ανεβαίνει η συνάρτηση στο 0 και πέφτει στο 1 αλλά ταλαντώνεται στην μέγιστη τιμή της ενώ για μεγαλύτερα h η μέγιστη τιμή είναι περισσότερο σταθερή.

ΠΡΟΒΛΗΜΑ 2:

α) Για να χρησιμοποιήσω το Representer Theorem ορίζω την γραμμική θήκη Ω ($\text{span}\{z_1, z_2, \dots, z_n\}$) η οποία είναι γραμμικός υπόχωρος του V και αποτελείται από στοιχεία που είναι γραμμικοί συνδυασμοί των z_1, z_2, \dots, z_n .

Έστω επίσης ότι υπάρχει x το οποίο δεν ανήκει στον Ω αλλά ανήκει στο V . Θέλω να βρω έναν αντιπρόσωπο του x τον \hat{x} στο Ω .

Προφανώς $\hat{x} = a_1 z_1 + \dots + a_n z_n$ και $(x - \hat{x})$ Πρέπει να είναι κάθετο στο Ω (ώστε το \hat{x} να είναι το διάνυσμα με την μικρότερη απόσταση από το x από όλα τα διανύσματα του Ω). Αυτό σημαίνει ότι το εσωτερικό γινόμενο $\langle x - \hat{x}, y \rangle = 0$ Με y να είναι όλα τα διανύσματα που ανήκουν στον Ω .

Αν το παραπάνω εσωτερικό γινόμενο είναι 0 για $y = (z_1 \dots z_n)$ τότε μπορώ να θεωρήσω το \hat{x} σαν αντιπρόσωπο του x στο Ω .

Αντίστοιχα με τις συναρτήσεις $\Phi(x)$ και $\Phi'(x)$ θα έχω:

$$\Phi(x) = a_1 K(x, z_1) + \dots + a_n K(x, z_n)$$

$$\Phi'(x) = b_1 K(x, x_1) + \dots + b_n K(x, x_n) \text{ όπου } x_1, \dots, x_n \text{ οι υλοποιήσεις που έχω.}$$

Το $K(x,y)$ ονομάζεται πυρήνας mercer και είναι μια θετικά ορισμένη συνάρτηση.

Το εσωτερικό γινόμενο των παραπάνω 2 συναρτήσεων είναι:

$$\langle \Phi(x) - \Phi'(x), K(x, x_l) \rangle = 0$$

Επίσης ισχύει ότι:

$$\Phi(x) = \sum_{i=1}^n a_i K(x, z_i)$$

$$\langle \Phi(x), K(x, x_0) \rangle = \sum_{i=1}^n a_i K(x, x_i) K(x, x_0) = \sum_{i=1}^n a_i K(x_i, x_0) = \Phi(x_0)$$

Και με χρήση αυτών η σχέση του εσωτερικού γινομένου των συναρτήσεων γίνεται

$$\langle \Phi(x), K(x, x_l) \rangle = \langle \Phi'(x), K(x, x_l) \rangle \text{ δηλ. } \Phi(x_l) = \Phi'(x_l)$$

Άρα μπορώ αντί για το $\Phi(x_l)$ να αντικαθιστώ με τον αντιπρόσωπο του στο υπόχωρο Ω του V που περιέχει μόνο γραμμικούς συνδυασμούς.

Στην συνάρτηση $\Phi'(x)$ έχω άγνωστους μόνο τους συντελεστές a_i οπότε αν παραγωγίσω ως προς αυτούς μπορώ να λύσω γραμμικό σύστημα για να τους υπολογίσω.

β) Για τον όρο $\|\Phi(x)\|^2$ ισχύει ότι:

$$\begin{aligned} \|\Phi(x)\|^2 &= \|\Phi(x) + \Phi'(x) - \Phi'(x)\|^2 = \|\Phi(x)\|^2 + \|\Phi(x) - \Phi'(x)\|^2 \\ &+ 2 \langle \Phi(x) - \Phi'(x), \Phi'(x) \rangle \end{aligned}$$

Το παραπάνω εσωτερικό γινόμενο όμως είναι 0 (αρχή ορθογωνιότητας) διότι τα διανύσματα είναι κάθετα μεταξύ τους (αφού το $\Phi'(x)$ ανήκει στον Ω και $\Phi(x) - \Phi'(x)$ είναι κάθετο στον Ω)

Αρά προκύπτει ότι :

$\|\Phi(x)\|^2 \geq \|\Phi'(x)\|^2$ που σημαίνει ότι μπορώ να αντικαταστήσω το $\Phi(x)$ με $\Phi'(x)$ και στον τελευταίο όρο του προβλήματος βελτιστοποίησης και πλέον έχω μόνο να βρω τους συντελεστές .

